颜简

15005893916@163.com | github.com/JianYan11 | AI Infra / 机器学习系统工程师

个人概述：聚焦 AI Infra 与 Agent 系统，具备 GPU 调度、训练性能诊断、实时对话基础设施与 CUA 环境搭建经验；向 TEN Framework、OpenEnv、OpenAI parameter-golf 提交代码贡献。

教育背景

北京交通大学 | 詹天佑荣誉学院 | 通信工程本科（985 平台，101 计划）

北京大学 | 国家发展研究院 | 经济学双学位

香港中文大学 | 电子工程学系 | 访问学生

国家奖学金（2023）；“挑战杯”市赛二等奖；中国国际大学生创新大赛市级奖项。

项目经历

华为诺亚方舟实验室合作 | Computer-use Agent 环境与 Harness 进行中

- **环境部署与任务接入：**搭建 OSWorld2 的 Docker/KVM 桌面运行环境，将 CUA-Gym 的初始化、桌面操作与 reward 脚本接入本地执行链路，处理系统依赖、镜像和任务资源兼容问题。
- **Rollout 与证据采集：**实现 DeepSeek 驱动的 observation–action 循环，记录逐步截图、模型输出、动作、reward 和运行日志，支持任务复现、失败定位与轨迹检查。
- **评测与跨端适配：**建设 setup/reward 验证脚本；围绕 PC、Web、Android 梳理 reset、判分及资源回收边界，编写最小环境适配原型，并推进 Android 模拟器与可扩展环境管理方案验证。

声网 & OpenAI | AI 实时对话引擎与基础设施 2026.06–2026.08

- **平台工具：**使用 Rust 参与统一运维 CLI 建设，覆盖部署、Manifest Validation、Argo CD Diff/Sync、Release 与 Cluster Health Diagnostics。
- **测试自动化：**基于 Pytest 建设 Functional、Upgrade 与 Chaos Platform 测试，覆盖网络异常、Pod 自愈、灰度发布及扩缩容；核心链路验证由 **1–2 人天缩短至 30 分钟内**。
- **GitOps 交付：**基于 Argo CD 管理服务配置、环境 Overlay 与 Kubernetes Manifest，支持中国区及海外集群声明式部署、变更审计和回滚。

声网 | LLM 训推调度自动化与混部 2026.06–2026.08

- **资源准入：**基于 Kueue ResourceFlavor、ClusterQueue/LocalQueue 管理共享 GPU Pool，覆盖 **16 张 A100**、**256 vCPU 与 1 TiB Memory**，将 Excel 人工排期改为自动排队与准入。
- **混部与回归验证：**通过 Cohort 借调与抢占实现空闲配额复用、推理扩容时回收及训练重新准入；使用 Pytest 验证 Quota、StrictFIFO、Borrowing、Preemption 与缩容恢复。

声网 | 训练可观测与性能优化 2026.06–2026.08

- **可观测平台：**从 0 到 1 建设 Prometheus / Grafana / NVIDIA DCGM 指标与看板，对比 GPU 配额和实际利用率，支持任务级资源观察与训练排障。
- **瓶颈诊断：**定位 DataLoader 并行度不足及 Rank 0 同步 Checkpoint I/O 阻塞；优化加载、`/dev/shm` 与写盘路径，单 Batch 平均耗时 **1.5s 降至 0.5s**，吞吐提升至 **3 倍**。

开源贡献

TEN Framework ｜实时语音 Agent 的 Jev 思考模式路由

github.com/TEN-framework/ten-framework 11,149 Stars

- **扩展与编排：**开发 TypeSafe Jev 决策扩展及独立主控、模型扩展，提供可选的语音助手 graph，将 ASR、路由、LLM 与 TTS 串联，按输入选择快速回答或深度思考模式。
- **交互可靠性：**实现异步取消、超时兜底、ASR 轮次聚合与迟到事件处理；将路由结果、推理文本与语音输出分离，补充回归测试并保留默认 graph 行为。

Hugging Face OpenEnv ｜ RL 环境会话与资源生命周期

github.com/huggingface/OpenEnv 2,663 Stars

- **异常清理与资源所有权：**修复会话创建失败导致的 provider 资源泄漏；清理失败时阻止再次分配，保留原始异常并保证重试、关闭的幂等性，避免误停其他会话正在使用的共享资源。
- **回归验证：**新增 **60 个参数化生命周期用例**及 **4 个真实 Docker 故障注入测试**，覆盖启动、readiness、子会话构造、清理失败与恢复顺序。
- **FastMCP 4 迁移：**适配会话状态隔离、MCP wire schema 和 Harness sampling guard，保持既有 Gym API 边界；核心套件 **834 passed / 1 skipped**。

OpenAI parameter-golf ｜受限训练预算下的激活函数实验

github.com/openai/parameter-golf 5,198 Stars

- 将 MLP 的 ReLU^2 替换为 $\mathrm{LeakyReLU}(0.5)^2$，保留负区间梯度，提交基线改进代码与实验结果。
- **本地自测：**双 RTX 5090、600s 预算下，bpb 从 **1.3822 降至 1.2947**；两次运行分别为 1000 / 1947 steps，作为该运行条件下的实验结果报告。

科研经历

国家重点研发计划｜空间科学数据检测 IEEE DLCV 2025 第一作者 / Oral

- 参与中科院国家空间科学中心“空间科学大数据智能管理与分析挖掘”项目，研究频高图重建与检测；基于 **4,311 张** Iono4311 频高图对比五种模型，DETR 达到 **54.2% Accuracy / 9.2 FPS**，较 YOLOv3 准确率提升 **10.0 个百分点**、速度提升约 **26%**；公开论文代码与训练方法。

医学成像｜深度学习相位解缠 算法研究 / 工程实现

- 与香港中文大学、麻省理工学院相关研究团队合作，负责神经网络相位解缠算法设计、训练验证与工程实现，准确率提升 **18%**；推进第一作者论文投稿与国家发明专利申请。

工程实践与技术影响力

- **医学成像产品化：**在倍捷锐参与 C++ 算法重构与端侧 GPU 加速，项目在 HICOOL 展出，成像设备在清华医学相关机构应用。
- **端侧与技术分享：**使用 llama.cpp 在树莓派部署本地推理；调研 TensorRT / OSS 分级存储并完成团队分享；运营“颜简的学习笔记”，单篇 Agent 文章阅读量超过 **1,000**。

技术能力

系统与基础设施：Python、Rust、C++、Linux、Docker/KVM、Kubernetes、Kueue、Argo CD。

训练与 Agent 工程：PyTorch、DDP/NCCL、Prometheus/Grafana、pytest、MCP、Rollout / Evaluation Harness。